

1. Título provisional del proyecto "RetainHub: Sistema Inteligente de Alerta Temprana para la Fidelización de Clientes en E-commerce"

2. Discurso de ascensor

En el sector e-commerce, captar un cliente nuevo es 5 veces más caro que mantener uno actual. RetainHub analiza el comportamiento de compra, la frecuencia de navegación y las quejas históricas para identificar clientes en riesgo de abandono. Nuestra solución permite a los equipos de marketing actuar proactivamente con ofertas personalizadas antes de que el cliente se vaya a la competencia, recuperando hasta un 25% de los ingresos en riesgo.

3. El tema y el problema

- Situación actual: Las empresas acumulan gigabytes de datos de ventas (logs) pero no saben leer las señales de que un cliente está "desconectando".
- Qué duele: La pérdida silenciosa de clientes (Churn) que erosiona el margen de beneficio de forma constante.
- Por qué es importante: Identificar el patrón de abandono permite automatizar la retención y optimizar el presupuesto de marketing.

4. Objetivo principal "Construir un modelo predictivo de clasificación que permita identificar clientes con alta probabilidad de abandono para lograr reducir la tasa de rotación (churn rate) mediante campañas dirigidas".

5. Alcance inicial (IN / OUT)

- EN:
 - o Limpieza y transformación de datos históricos de ventas y perfiles de usuario.
 - o Creación de un modelo de Machine Learning (Clasificación binaria: ¿Se va o se queda?).
 - o Generación de un reporte con el "Top 100" clientes en riesgo.
- AFUERA:
 - o Implementación de la pasarela de envío de correos o SMS.
 - o Seguimiento en tiempo real de la navegación web (nos basaremos en registros estáticos).

6. Usuarios / Partes interesadas

- Quién lo usa: Analistas de marketing y gestores de Customer Experience.
- Quién decide: Responsable de Marketing o CRM Manager.
- Quién se beneficia: El departamento financiero (mejor flujo de caja) y los clientes (reciben mejores ofertas).

7. Propuesta de solución (Alto nivel) El proyecto es un pipeline de datos lineal:

1. Ingesta: Carga de ficheros CSV o bases de datos relacionales con el historial de compras.
2. Ingeniería de Características: Crear variables como "días desde la última compra" o "gasto total acumulado".
3. Modelado: Entrenamiento de un algoritmo sencillo pero potente (Random Forest o Regresión Logística).
4. Salida: Un listado de clientes con su "score" de riesgo (0 a 100%).

8. Datos (Estimación inicial)

- Fuentes: Utilizaremos conjuntos de datos públicos estándar y de alta calidad (ejemplo: Kaggle - Telco Customer Churn o Online Retail Dataset).
- Tipo de datos: Tabulares (filas y columnas). Muy fácil de procesar.
- Riesgos: Ninguno, al ser datos públicos y anonimizados no hay problemas de privacidad (GDPR).
- 9. Viabilidad técnica
- Fácil: El procesamiento de los datos con librerías como Pandas . Es un entorno muy controlado.
- Difícil: Equilibrar el conjunto de datos (normalmente hay muchos más clientes que se quedan que clientes que se van).
- Tecnología: Python en un entorno de Google Colab o Jupyter Notebooks . Es colaborativo y no requiere instalación de servidores complejos.

10. Riesgos principales y plan B

- Riesgo: El modelo no predice bien porque los datos son antiguos.
 - o Plan B: Centrarse en un análisis descriptivo profundo (segmentación de clientes RFM: Recencia, Frecuencia, Valor Monetario) en lugar de solo predicción.

- Riesgo: El equipo se ataca con la limpieza de datos.
 - o Plan B: Utilizar una herramienta de Auto-ML (como PyCaret) para agilizar la fase de modelado.

11. Reparto

Carlos Suárez Sánchez : Responsable de Datos y ETL

- Carga de datos: Localizar y descargar los datasets de fuentes públicas (Kaggle/Online Retail).
- Limpieza inicial: Manejo de valores nulos y duplicados en el historial de ventas.
- Transformación: Asegurar que los datos tabulares sean procesables en Pandas.
- Documentación de datos: Redactar el análisis descriptivo inicial para el reporte.

Ángela María Baena Alba: Ingeniero de Características

- Creación de variables: Programar las métricas clave como "días desde la última compra" y "gasto total acumulado".
- Segmentación RFM: Liderar el análisis de Recencia, Frecuencia y Valor Monetario (Plan B en caso de fallos en el modelo).
- Preparación para el modelo: Realizar la codificación de variables categóricas y normalización de datos.

Mariano Correa Carballo: Científico de Datos (Modelado)

- Entrenamiento: Implementar los algoritmos de clasificación (Random Forest o Regresión Logística).
- Gestión del desequilibrio: Aplicar técnicas para corregir la falta de equilibrio entre clientes que se van vs. los que se quedan (el punto "difícil" del proyecto).
- Evaluación: Calcular la precisión del modelo y generar el "score" de riesgo de 0 a 100%.
- Plan B Tecnológico: Estar preparado para usar PyCaret (Auto-ML) si la limpieza se complica.

Rodrigo Núñez Gómez: Analista de Negocios y Presentación

- Generación de Salida: Crear el reporte del "Top 100" clientes en riesgo.
- Visualización: Diseñar gráficos que muestren los patrones de abandono (Churn) para los interesados.
- Alineación estratégica: Redactar las recomendaciones para los equipos de marketing y CRM basadas en las predicciones.
- Entorno Colab: Mantener el Jupyter Notebook organizado y documentado para la entrega final.

Plan de Acción: Semana 1

1. Día 1-2: Selección y Preparación del Dataset (Integrante 1) El Integrante 1 debe localizar y descargar los conjuntos de datos de fuentes públicas como Kaggle (Telco Customer Churn u Online Retail). El objetivo es realizar una limpieza inicial de nulos y duplicados para que el resto del equipo tenga una base sólida sobre la cual trabajar..

2. Día 3: Configuración del Entorno Colaborativo (Integrante 4) El Integrante 4 debe configurar el entorno de Google Colab o Jupyter Notebook. Es vital que este espacio esté organizado desde el principio para que todos puedan subir su código y documentar el proceso de forma centralizada..

3. Día 4-5: Ingeniería de Variables y Análisis RFM (Integrante 2) Una vez que los datos estén limpios, el Integrante 2 debe programar las métricas clave: Recencia, Frecuencia y Valor Monetario (RFM). Esto es fundamental no solo para el modelo, sino como "Plan B" descriptivo si la predicción fallara..

4. Día 5-6: Primer Entrenamiento y Gestión de Desequilibrio (Integrante 3) Con las listas de variables, el Integrante 3 debe implementar un algoritmo inicial (Random Forest o Regresión Logística). Su tarea crítica aquí es aplicar técnicas para corregir el desequilibrio entre clientes que se van y los que se quedan, que es el punto más difícil del proyecto..

5. Día 6-7: Generación de Resultados y "Top 100" (Integrantes 3 y 4) El Integrante 3 calcula el puntaje de riesgo (0-100%) para cada cliente. Con estos datos, el Integrante 4 genera el reporte del "Top 100" clientes en riesgo y comienza a diseñar los gráficos de los patrones de abandono..

6. Día 7: Revisión de Viabilidad y Alineación (Todo el equipo) Reunión rápida para verificar si el modelo predice correctamente. Si la limpieza fue muy compleja o los resultados son pobres, el Integrante 3 activará el uso de PyCaret (Auto-ML) para agilizar el modelado antes de la entrega final.

- Canales de comunicación: Telegram y Google Meet.
- Disponibilidad: Dependiendo del trabajo de cada uno.
- Frecuencia reuniones: 1-2 por semana.
- Reglas básicas:
 - No se sube nada sin avisar ni sin aprobación del grupo.
 - Se respeta el reparto pero puede haber ayudas.

REPOSITORIO INICIAL

Aporto estructura copiada del archivo Readme.md

RetainHub: Sistema Inteligente de Alerta Temprana

Objetivo

Construir un modelo predictivo de clasificación para identificar clientes con alta probabilidad de abandono (Churn) y reducir la tasa de rotación mediante campañas de marketing dirigidas..

Miembros del Equipo

Integrante 1 : Responsable de Datos y ETL (Carga y limpieza).

Integrante 2 : Ingeniero de Características (Métricas RFM y variables).

Integrante 3 : Científico de Datos (Modelado y algoritmos).

Integrante 4 : Analista de Negocios y Presentación (Visualización y entorno).

Organización del Repositorio

Se utilizará un flujo de trabajo basado en ramas (branches) por integrante para evitar conflictos en el código principal (main). Las entregas parciales se consolidarán en la carpeta src/.

3. Estructura de Alfombras Recomendada

Esta es la disposición de archivos que deben aparecer en el repositorio:

Texto sin formato

RetainHub/

```
├── docs/
│   └── Fase0_Presentacion_y_Viabilidad.pdf # Documento actual del
        proyecto [cite: 70-155]
├── src/
│   ├── cleaning.py    # Tareas del Integrante 1 [cite: 121]
│   ├── engineering.py # Tareas del Integrante 2 [cite: 125]
│   └── modeling.ipynb  # Tareas del Integrante 3 (Notebook Colab) [cite:
        129, 138]
├── data/
│   └── .gitkeep        # Para mantener la carpeta en Git sin subir datasets
        pesados [cite: 105]
├── environment/
│   └── requirements.txt # Librerías necesarias (Pandas, Scikit-learn,
        PyCaret) [cite: 109, 117]
├── README.md          # Información general del proyecto
└── .gitignore          # Filtro de archivos no deseados
```