



RetainHub

Sistema Inteligente de Alerta Temprana para la
Fidelización de Clientes en E-commerce

Trabajo de: Curso de Especialización de Inteligencia Artificial y Big Data

Asignatura: Proyecto de Inteligencia Artificial y Big Data

Autores: Ángela Baena, Mariano Correa, Rodrigo Núñez y Carlos Suárez

Profesor: José Miguel Ruiz Guevara

Centro: iFP Innovación en Formación Profesional

Año: 2026



ÍNDICE

- 1. Título del Proyecto e Integrantes**
- 2. Resumen Ejecutivo**
- 3. Descripción Funcional del Sistema**
- 4. Alcance Definitivo (ENTRADA/SALIDA)**
- 5. Arquitectura del Sistema (Alto Nivel)**
- 6. Tecnologías Seleccionadas**
- 7. Modelo de Datos**
- 8. Datos**
- 9. Ética, Legalidad y Accesibilidad**
- 10. Backlog Inicial (Historias de Usuario)**
- 11. Plan de Trabajo**
- 12. Estrategia de Desarrollo**
- 13. Repositorio del Proyecto (Estructura)**
- 14. Riesgos Técnicos Actualizados**
- 15. Ayuda de Inteligencia Artificial**

Informe de Fase 1: Documentación y Diseño Técnico - Retain Hub

1. Título del Proyecto e Integrantes

- **Nombre del proyecto:** Retain Hub: Sistema Inteligente de Alerta Temprana para la Fidelización de Clientes en E-commerce.
- **Integrantes y Roles:**
 - Carlos Suárez Sánchez: Responsable de Datos y ETL (Carga, limpieza y transformación).
 - Ángela María Baena Alba: Ingeniería de Características (Métricas RFM y preparación de variables).
 - Mariano Correa Carballo: Científico de Datos (Modelado, algoritmos y gestión de desequilibrio).
 - Rodrigo Núñez Gómez: Analista de Negocios y Presentación (Visualización, reporte y entorno Colab).

2. Resumen Ejecutivo

Retain Hub aborda el alto coste de adquisición de clientes en el e-commerce, donde captar un nuevo usuario es 5 veces más caro que retenerlo. El problema es la pérdida silenciosa de clientes (Churn) por la incapacidad de interpretar señales de "desconexión" en los datos de ventas. Proponemos un sistema que analiza el comportamiento histórico para predecir el riesgo de abandono mediante Machine Learning. La solución genera un puntaje de riesgo y un listado de los 100 clientes más críticos, permitiendo recuperar hasta un 25% de los ingresos en riesgo.

3. Descripción Funcional del Sistema

- **Qué hace:** El sistema funciona como herramienta de soporte para marketing, clasificando clientes según su probabilidad de fuga..
- **Flujo general:** Ingesta de datos $\rightarrow$ Creación de métricas RFM $\rightarrow$ predicción por clasificación $\rightarrow$ Generación de informe.
- **Casos de usuario:** El analista consulta el "Top 100" para lanzar campañas de cupones de descuento personalizados.

- Capacidades: Limpieza de datos y creación de variables de comportamiento (recencia, gasto total).
- Limitaciones: No realiza envío automático de mensajes ni seguimiento web en tiempo real.

4. Alcance Definitivo (ENTRADA/SALIDA)

Incluye (IN)+2	Excluye (OUT)+1
Limpieza y transformación de datos históricos.	Implementación de pasarela de envío (Email/SMS).
Modelo de ML de clasificación binaria.	Seguimiento de navegación web en tiempo real.
Análisis de segmentación RFM.	Instalación de servidores físicos complejos.
Reporte "Top 100" clientes en riesgo.	Integración con API de terceros para ejecución.

5. Arquitectura del Sistema (Alto Nivel)

El proyecto se basa en un pipeline lineal ejecutado en la nube para facilitar la colaboración.

- Pipeline de datos: Proceso secuencial desde carga de CSV hasta ingeniería de características.
- Servicios ML: Modelos entrenados (Random Forest o Regresión Logística) para predecir el Churn.
- Salida: Reporte estático de clientes con puntaje de riesgo (0-100%) y visualizaciones de patrones.
- Entorno: Google Colab como plataforma de ejecución colaborativa.

6. Tecnologías Seleccionadas

- Lenguaje: Python , por su ecosistema de librerías de análisis .
- Librerías: Pandas (procesamiento tabular) y Scikit-learn (algoritmos de ML)

- Alternativa (Plan B): PyCaret para agilizar el modelado si la limpieza es compleja .
- Herramientas auxiliares: Google Colab para trabajo documentado en la nube .

7. Modelo de Datos

El sistema utiliza una estructura tabular procesada en DataFrames de Pandas.

- Recencia: Días desde la última compra.
- Frecuencia: Número de transacciones en el período.
- Valor Monetario: Gasto total acumulado.
- Target (Clase): Variable binaria que indica si el cliente abandonó o no.

8. Datos

- Fuente: Conjuntos de datos públicos de alta calidad (Kaggle - Online Retail / Telco Churn).
- Realidad: Datos reales procedentes de negocios, pero debidamente anonimizados.
- Riesgos: Desequilibrio de clases y posible degradación por antigüedad de los registros..
- Volumen: Estimación de gigabytes en registros de ventas.

9. Ética, Legalidad y Accesibilidad

- Privacidad: Cumplimiento de estándares al no manejar Información de Identificación Personal (PII).
- Sesgos: Riesgo de desequilibrio en el conjunto de datos (pocas fugas vs. muchas permanencias).
- Mitigación: Uso de métricas como F1-score y técnicas de balanceo para asegurar un modelo justo.

10. Backlog Inicial (Historias de Usuario)

Historia de Usuario	Criterio de Aceptación (Referencia Técnica)
Limpieza: Como Analista, quiero limpiar valores nulos.	El conjunto de datos final debe tener un 0% de nulos en campos clave.
RFM: Como ingeniero, quiero calcular la recencia.	Los valores de recencia deben ser enteros positivos.
Top 100: Como Marketing, quiero ver el listado de riesgo.	Exportación de un CSV ordenado por probabilidad de fuga.
Modelado: Como científico de datos, quiero entrenar Random Forest.	El modelo debe superar el 75% de precisión en validación.
Balanceo: Como científico de datos, quiero aplicar técnicas de balanceo.	Uso de SMOTE o submuestreo documentado en el cuaderno.
Entorno: Como desarrollador, quiero configurar Colab.	Repositorio conectado y entorno de ejecución accesible al equipo.

11. Plan de Trabajo

- Días 1-2: Selección y limpieza del Dataset (Responsable: Carlos).
- Día 3: Configuración de Google Colab (Responsable: Rodrigo).
- Días 4-5: Ingeniería de variables y análisis RFM (Responsable: Ángela).
- Días 5-6: Entrenamiento de modelos y equilibrio de clases (Responsable: Mariano).
- Día 7: Generación de resultados (Top 100) y visualización (Equipo).

12. Estrategia de Desarrollo

- Flujo Git: Uso de ramas (branches) por integrante para evitar conflictos en main.
- Integración: Consolidación de entregas parciales en la carpeta src/.
- Validación: Reuniones semanales para aprobación grupal de cambios.

13. Repositorio del Proyecto (Estructura)

El proyecto sigue la estructura jerárquica obligatoria para asegurar la trazabilidad.:

- repo/: Raíz del proyecto.
 - docs/: Contiene Fase1_Documentacion_y_Disenio_Tecnico.pdf y arquitectura.png .
 - src/: Carpeta para el código fuente y cuadernos.
 - data/: Para el almacenamiento de conjuntos de datos.
 - environment/: Configuración del entorno.
 - README.md: Descripción, integrantes y guía de ejecución.

14. Riesgos Técnicos Actualizados

Riesgo	Impacto	Probabilidad	Mitigación
Datos antiguos.	Alto	Medios de comunicación	Pivotar un análisis descriptivo RFM.
Desequilibrio de clases.	Alto	Alta	Técnicas de corrección (Sobre/Submuestreo).
Bloqueo en limpieza.	Medio	Medios de comunicación	Uso de Auto-ML (PyCaret).

15. Ayuda de Inteligencia Artificial.

- Redacción.
- Estructura del documento.
- Limpieza.