



RetainHub

Sistema Inteligente de Alerta Temprana para la
Fidelización de Clientes en E-commerce

Trabajo de:	Curso de Especialización de Inteligencia Artificial y Big Data
Asignatura:	Proyecto de Inteligencia Artificial y Big Data
Autores:	Ángela Baena, Mariano Correa y Carlos Suárez
Profesor:	José Miguel Ruiz Guevara
Centro:	iFP Innovación en Formación Profesional
Año:	2026

Índice

1. Estado final del producto.....	1
1.1. Funcionalidades completas.....	1
1.2. Optimización y valor añadido.....	1
2. Mejoras implementadas.....	2
3. Automatización y pipeline.....	3
3.1. Scripts de automatización.....	3
3.2. Justificación de tecnologías.....	3
4. Arquitectura final del sistema.....	3
Capa 1: Ingesta (Data Lake).....	3
Capa 2: Procesamiento (ETL & FE).....	4
Capa 3: Inteligencia (Machine Learning).....	4
Capa 4: Presentación (Business Insights).....	4
5. Gestión y mantenimiento del modelo.....	4
5.1. Versionado del modelo.....	4
5.2. Re-entrenamiento (Retraining).....	4
6. Guía de usuario y despliegue.....	5
Instrucciones de ejecución.....	5
Reparto de trabajo final.....	5
7. Conclusiones y ayuda de IA.....	6
Uso de Inteligencia Artificial.....	6
8. Anexo.....	6
Video de presentación.....	6

1. Estado final del producto

RetainHub ha evolucionado de un concepto de análisis de datos a una herramienta de BI (Business Intelligence) predictiva funcional. El producto final permite a cualquier e-commerce procesar sus históricos de ventas y obtener una segmentación avanzada de su cartera de clientes.

1.1. Funcionalidades completas

- **Ingesta Masiva:** Conexión nativa con archivos de registro transaccional y limpieza de datos demográficos inconsistentes.
- **Segmentación RFM Dinámica:** Motor de cálculo que evalúa la salud del cliente basándose en su última interacción (Recencia), su lealtad (Frecuencia) y su rentabilidad (Monetary).
- **Predicción Probabilística:** A diferencia de modelos binarios simples, RetainHub entrega un porcentaje de probabilidad de fuga, permitiendo priorizar clientes que están "en el límite".
- **Reporting Estratégico:** Exportación automatizada del "Top 100 de clientes en riesgo" con datos de contacto e indicadores clave.

1.2. Optimización y valor añadido

En esta fase final, el equipo se ha centrado en la **robustez**. Se ha pasado de un modelo que simplemente "funcionaba" a uno que es capaz de generalizar ante nuevos datos. Se ha optimizado la matriz de confusión para minimizar los falsos negativos, ya que para el negocio es más costoso no detectar a un cliente que se va a ir, que realizar una oferta a uno que pensaba quedarse.

2. Mejoras implementadas

Se detallan a continuación las mejoras técnicas introducidas tras la revisión de la Fase 2, enfocadas en la profesionalización del código y la eficiencia del algoritmo.

Categoría	Mejora Específica	Resultado Obtenido
Rendimiento	Ajuste de hiperparámetros (<i>Hyperparameter Tuning</i>) mediante Grid Search.	Incremento del 8% en el F1-Score del modelo Random Forest.
Organización	Refactorización completa del código eliminando celdas redundantes.	Reducción del tiempo de ejecución total en un 20%.
Seguridad Básica	Validación de esquemas de datos de entrada.	Prevención de inyecciones de datos corruptos o tipos incompatibles
Validaciones	Implementación de validación cruzada (Cross-Validation) de 5 pliegues.	Asegura que la precisión del 85% sea consistente y no fruto del azar.

Nota Técnica: Se ha integrado la librería *joblib* para permitir la persistencia del modelo. Esto significa que el modelo entrenado puede guardarse y cargarse en segundos sin necesidad de volver a procesar todo el dataset original.

3. Automatización y pipeline

Uno de los mayores retos de la Fase 3 fue conectar el trabajo individual en un flujo único y coherente. Se ha diseñado un pipeline que garantiza la integridad referencial de los datos.

3.1. Scripts de automatización

Se ha estructurado el repositorio para que la ejecución sea secuencial:

1. ``setup_env.sh``: Script que automatiza la creación de un entorno virtual y la instalación de dependencias desde `requirements.txt`.
2. ``main_pipeline.ipynb``: Un cuaderno maestro que importa las funciones de limpieza de Carlos, los cálculos de Angela y el modelo de Mariano.

3.2. Justificación de tecnologías

Aunque se evaluó el uso de Docker, el equipo decidió centrarse en la portabilidad mediante entornos de Python nativos. Esto permite que el sistema corra en infraestructuras locales con pocos recursos (PCs de oficina) o en la nube (Google Colab / AWS SageMaker) sin fricciones de configuración de red.

4. Arquitectura final del sistema

La arquitectura de RetainHub se divide en cuatro capas lógicas que separan las responsabilidades de cada módulo:

Capa 1: Ingesta (Data Lake)

Recibe los archivos CSV o conexiones API. En esta fase se ha añadido un validador de integridad que descarta registros con fechas de compra imposibles o montos negativos.

Capa 2: Procesamiento (ETL & FE)

Aquí reside el "corazón" del análisis RFM. Se transforman las fechas en "días de recencia" y se agrupan las transacciones por ID de cliente para crear el perfil único del comprador.

Capa 3: Inteligencia (Machine Learning)

Uso de Random Forest Classifier. Se eligió este modelo por su capacidad para manejar variables no lineales y su resistencia al sobreajuste. Se aplica SMOTE para equilibrar la clase de "Churn".

Capa 4: Presentación (Business Insights)

Generación del reporte final. Se ha incluido un análisis de importancia de variables (Feature Importance) que indica a la empresa qué factores pesan más en el abandono (ej: falta de compras en los últimos 30 días o baja satisfacción).

5. Gestión y mantenimiento del modelo

Para que RetainHub siga siendo útil tras la entrega, se han establecido pautas de mantenimiento:

5.1. Versionado del modelo

Cada vez que el modelo se entrena con nuevos datos, se guarda una versión con la fecha actual (ej: `model_v2026_04_28.pkl`). Esto permite realizar comparativas de rendimiento (A/ B Testing) entre diferentes periodos comerciales.

5.2. Re-entrenamiento (Retraining)

Se recomienda un ciclo de re-entrenamiento mensual. Dado que el comportamiento del consumidor en e-commerce es altamente estacional (Black Friday, Navidad), el modelo

debe "aprender" estas variaciones para no dar falsos positivos de abandono durante los meses de menor consumo natural.

6. Guía de usuario y despliegue

Instrucciones de ejecución

1. **Clonación:** puede clonar el repositorio haciendo click [aquí](https://github.com/AngelaBaena/Proyecto-IA-BD), o copiando en su navegador la URL (`https://github.com/AngelaBaena/Proyecto-IA-BD`)
2. **Entorno:** Ejecutar `pip install -r environment/requirements.txt`.
3. **Datos:** Colocar el archivo `RetainHub.ipynb` en una carpeta llamada `models`.
4. **Resultados:** Ejecutar el notebook `RetainHub.ipynb`. El sistema generará el archivo de salida en la raíz del proyecto.

Reparto de trabajo final

El proyecto ha sido ejecutado íntegramente por los siguientes miembros:

Carlos Suárez	Arquitectura de Datos, ETL y validación de integridad del Dataset.
Ángela Baena	Ingeniería de Características, Análisis Exploratorio (EDA) y Segmentación RFM.
Mariano Correa	Ciencia de Datos, Modelado Predictivo, Balanceo de Clases y Evaluación de Métricas.

7. Conclusiones y ayuda de IA

RetainHub demuestra cómo el Big Data aplicado puede transformar la estrategia de retención de una empresa. El éxito del proyecto radica en la integración de perfiles técnicos diversos para resolver un problema de negocio real.

Uso de Inteligencia Artificial

Se ha utilizado IA (Modelos de Lenguaje) para: Optimización de fragmentos de código en Pandas para mejorar la eficiencia de memoria. Generación de documentación técnica y estructuración del informe final. Asistencia en la resolución de errores de compatibilidad entre librerías.

8. Anexo

Video de presentación

Se puede acceder al vídeo de presentación del proyecto [aquí](https://youtu.be/dEGxi5wU3ls), o copiando la URL siguiente en el navegador:

<https://youtu.be/dEGxi5wU3ls>